动态扰动下卫星任务计划的低干扰韧性修复方法

摘要—计划感知局部修复旨在计划已下发、部分任务进入操作协调链的条件下实现快速低干扰的计划修复，是支撑动态对地观测卫星调度的关键而又具挑战性的技术。现有前沿方法多聚焦于从零开始的静态规划、扰动后的全局重优化或稳定优先的最小修复，却通常忽略了已下发承诺、扰动局部性与可控插入规模之间的复杂耦合关系，导致保留任务被大量移动和可恢复效用被错失。预测—反应式调度与冻结区间重调度所遵循的先承诺、后局部修复原则，为已下发前缀约束下的计划修复提供了可能。因此，我们提出计划感知局部修复方法（PALR），这是一种新的把已下发承诺与扰动局部性作为硬约束的修复规则，其修复控制要素包括冻结前缀硬保留、以扰动为中心的邻域编辑、显式插入预算 B 和词典序候选裁决，用于实现局部可控的低干扰修复。然后，我们提出基于冻结前缀保持、扰动中心邻域编辑和预算控制修复算子的局部修复流程，可在在线扰动响应下调节效用恢复与计划稳定，提升低干扰快速修复能力。该方法通过联合利用冻结前缀与可行性硬约束、邻域宽度与编辑范围、插入预算与效用恢复之间的关系，提升效用恢复并保持计划稳定。统一协议下的对比与消融实验表明，PALR 在保持与贪心全局重优化相当效用的同时显著降低修复干扰成本；与最强基线相比，其插入任务负担由 0.539 降为 0.335、减少约 37.8%，修复时延由 0.413 毫秒降低至 0.084 毫秒。

***Index Terms*—对地观测卫星调度，已下发前缀修复，低干扰重调度，计划感知局部修复，在线计划恢复**

I. 引言

在计划已下发后的扰动修复这一场景下，对地观测卫星调度领域已在观测选择、可见窗口匹配、机动约束处理和多星协同上取得了显著成就。尽管现有调度方法在静态计划构建、应急任务插入和全局重优化上表现优异，但在计划已下发后的扰动修复这一核心任务上，仍存在难以同时兼顾已下发计划保持、局部扰动响应和修复效率等不足。也就是说，一旦计划进入操作协调链，调度器面对的就不再是纯粹的效用最大化问题，而是既有承诺约束下的修复问题。

现有研究采用了从多种角度推进对地观测调度的总结性策略。根据已有成果，这些方法主要分为三类：第一类是从零开始的静态规划，通过搜索、学习和数学规划构造高质量计划，以达成静态场景下的效用最优，但这类方法没有回答部分计划下发后应如何修复。第二类是扰动后的全局重优化方法，即使扰动是局部的，也会移动大量保留任务、重新打开操作方期望保持不变的决策，缺失对已下发承诺的保护能力。而第三类是稳定优先的局部修复方法，若实现得过于刚性，会把可恢复的效用白白丢弃，缺失对局部可行紧急任务的吸收能力。为了确保既保护承诺又不过度保守，本文关注把计划稳定作为算法约束嵌入修复规则的核心能力，属于第三类的改进方向。

当前在扰动修复这一场景下，更强的全局搜索会扩大可编辑范围并抬高修复时延，而过度保守的稳定优先修复则会浪费扰动新释放出来的空闲资源。这样的设计没有把已下发承诺、扰动局部性和可控插入规模统一建模的能力，反而在计划保持、局部响应和低时延三项需求需要同时满足时暴露出短板。

为了避免这一困境，我们将研究核心确定为把动态对地观测调度建模为已下发前缀约束下的局部可控修复，而非全局重规划。即通过冻结前缀硬保留、以扰动为中心的局部编辑和显式插入预算这三项控制，来在效用恢复与干扰控制之间取得平衡。经过这样处理后的修复问题，通过限定编辑范围并显式记账每一次改动，理论上可以得到既可执行又低干扰的修复结果。图 1直观展示了全局重优化与 PALR 局部修复在编辑范围和承诺保持方式上的差异。

在追求低干扰快速修复这一核心需求的同时，扰动处理面临着巨大挑战：修复往往受时间约束，需要在有限时间内完成从扰动解析到可行计划输出的关键操作链，并同时覆盖任务取消、紧急插入和奖励更新三类扰动，面临计算资源和响应时延的严格限制。

为了解决上述问题，我们参考了预测—反应式调度

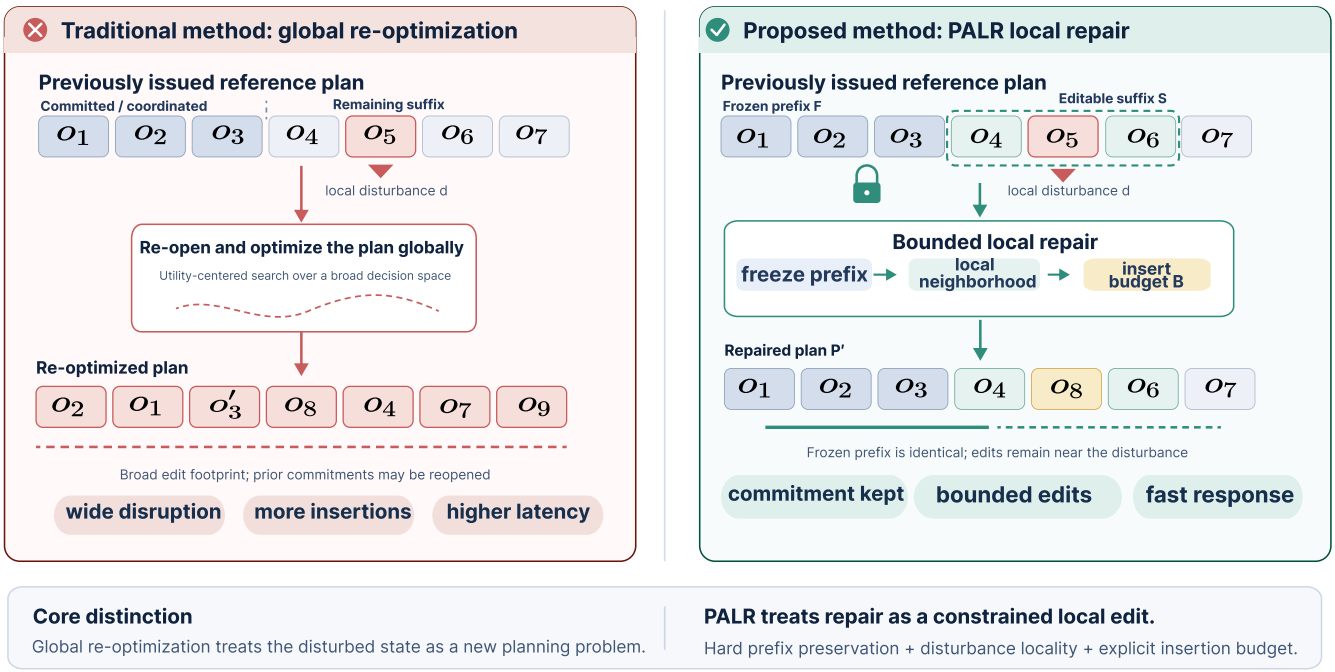


图 1. 全局重优化与 PALR 局部修复的概念对比。全局重优化会重新打开已协调决策并形成较宽的编辑足迹；PALR 保持已下发前缀，仅在扰动邻域内执行受插入预算约束的局部编辑。

和冻结区间重调度的思路，即先冻结计划的一部分、把编辑限制在局部区域、再用稳定性来权衡效用。该思路中“先承诺、后局部修复”的原则与本文追求的低干扰修复目标一致。基于这一思路的启发，我们构建 PALR 修复规则，并通过邻域裁剪与预算控制加以约束，从而达到局部可控的快速修复能力。具体来说，冻结前缀硬保留机制通过把已下发的前缀标记为不可修改来保护承诺，并收集飞控与地面协调约束作为硬约束。其次，以扰动为中心的邻域编辑机制扮演限制干扰扩散的角色，其可编辑范围是通过围绕扰动边界设定邻域宽度得来的，并由插入预算 B 指导新任务接纳规模的控制。

与直接把扰动后状态当作新规划实例的现有方法不同，PALR 可以在保持已下发计划不变的前提下完成局部修复。PALR 所研究的低干扰修复的重点在于把冻结前缀有效性和插入预算提升为一等的、可审计的量，这与仅在优化后才评估稳定性的传统方法存在本质区别与创新。综上所述，我们在本研究中的贡献如下：(1) 我们把动态对地观测调度形式化为已下发前缀修复问题，使冻结前缀保持、效用恢复和干扰控制被联合评估，而非仅由静态目标值衡量；(2) 我们提出 PALR 修复规则，将显式冻结前缀处理、有界可编辑邻域和作为可解释控制变量的插入预算 B 统一在一条可审计的修复路径中；(3) 我们在统一的对地观测调度实验协议下给出考虑方差的实验证据，通过与贪心和基于搜索的重规划基线的多指标比较，刻画了有界局部修复的适用区间及其已知的退化和升级边界。

本文其余部分安排如下。第 II 节将本文置于对地观测调度规划与重调度修复的背景中加以定位。第 III 节定义系统模型、协议边界、形式化修复问题与设计需求。第 IV 节给出 PALR 规则及其形式化性质。第 V 节报告实验证据。

II. 相关工作

A. 对地观测规划与预测-反应式重调度

近年来，对地观测卫星调度取得了显著进展，带来了更高的计划质量与更强的约束处理能力。与此同时，分布式约束优化、在线应急调度、图引导搜索与约束规划的提出进一步拓展了对地观测调度的静态效用上界 [1]–[6]。从头构建的规划器通过在候选观测集合上进行搜索、学习和数学规划实现了高质量的静态计划 [3], [5]。从静态规划出发，更复杂的框架如分布式任务规划、周期性星上重调度、变尺度深度强化学习调度器与双层优化模型进一步扩展了动态响应能力 [7]–[11]。在对地

观测之外，制造与生产领域把重调度视为效率与稳定性的权衡，多目标重调度综述、深度强化学习动态调度综述与数字孪生驱动调度综述为已发布计划的可问责修复提供了相邻的方法背景 [12]–[14]。然而，上述对地观测方法主要依赖从零构建或全局重优化，面临已发布承诺缺乏显式保护，并且缺少可见窗口、机动可行性和冻结前缀审计等对地观测专有结构的建模。此外，有界扰动模型与修复成本权衡等方法通过限制单次重调度的改动幅度，以有效缓解上述可问责性缺失 [15], [16]。这些方法的基础是把稳定性作为一等约束或权衡目标，其对修复足迹的关注为已下发前缀约束下的修复提供了启发，也启发了本文把冻结前缀与插入预算提升为一等硬约束的研究思路。

B. 学习引导的破坏与修复

学习引导的大邻域搜索的兴起推动了自适应局部修复的发展，用户期望在受扰的组合优化实例上获得更高质量与更强迁移能力的修复 [17]–[23]。大邻域搜索也被应用于经典调度问题，如公交司机排班 [24]；而混合整数规划的学习式加速（如学习式后门变量）与多智能体强化学习中的大邻域思想则从不同角度拓展了这一方法族 [25], [26]。然而，开放式构造与改进倾向为已发布计划修复带来挑战。在承诺保持约束下，学习引导的局部修复是一种实用的解决方案。可迁移局部策略、记忆增强强化框架与跨问题迁移方法通过学习邻域控制平衡了搜索质量与迁移需求 [27]–[31]；面向大规模路由的全局划分加局部构建、基于扩散的神经求解器与抽象约束规约上的局部搜索进一步丰富了求解器设计 [32]–[34]；面向卫星的局部注意力神经重规划器通过局部化建模提高了单星敏捷光学卫星调度的适应性 [35]。这类基于图的组合优化与搜索控制方法的更广背景可见于相关综述与树搜索实践 [36]–[38]。这两类方法都体现了自适应局部修复的趋势，以确保受扰后的高质量恢复，尽管学习式邻域控制偏向搜索质量与迁移，而卫星神经重规划器偏向领域专有结构，二者有所不同，但都忽略了冻结前缀语义与可审计的扰动权衡。本文提出的方法通过把冻结前缀保持、局部邻域编辑与显式插入预算组织为一条可审计的修复流程，针对上述局限系统解决已发布计划修复中承诺保持与低干扰响应难以同时满足的问题。

III. 系统与问题建模

A. 系统概述

我们沿用已有工作的对地观测调度任务形式化：一颗敏捷卫星需要为超额认购的候选观测集合安排计划，每个观测都带有可见窗口、效用值，以及由机动和时序行为引出的可行性约束 [3]。计划由一串按时间排序的被选观测构成。在动态场景下，调度器收到的是一个任务集合连同一份既有计划，而这份计划的前缀可能已经被操作方使用。

设 $P = (o_1, \ldots, o_m)$ 为扰动前的参考计划，k 为下发后第一个可编辑位置。前缀 $F = (o_1, \ldots, o_{k-1})$ 被视为冻结部分，后缀 $(o_k, \ldots, o_m)$ 仍可编辑。扰动描述子 d 指定需要吸收的改变：某个已排任务可能被取消，某个新的紧急任务可能到达，或者效用发生更新。修复问题要求给出一份新的可行计划 P'，它保持 F 不变、满足对地观测约束，并在效用与干扰之间取得可辩护的折中。

修复工作流分为两个阶段。首先，初始规划器为当前任务集合生成一份参考计划。其次，一旦该计划的一部分被视为已下发，扰动发生，修复模块被调用。修复模块必须考虑已承诺的计划，判断剩余后缀中有多少需要解锁，生成局部候选编辑，并足够快地返回一份新的可行后缀以供在线使用。这一工作流与普通的静态重规划有本质差异：规划状态现在包含先前已承诺的决策、扰动类型和剩余的自由度，因此修复算法必须跟踪计划语义，而不仅仅是目标值。一个忽略冻结前缀的方法在朴素效用记账下可能看起来很强，但因为它使已协调好的工作失效而在操作上不可接受。

B. 形式化问题定义

1) 任务与计划表示: 一个观测任务是一个元组 $o = (w_{\text{start}}, w_{\text{end}}, u, \theta)$，其中 $[w_{\text{start}}, w_{\text{end}}]$ 是卫星可以对目标成像的可见窗口，$u \in \mathbb{R}^+$ 是效用值，θ 编码几何与操作约束（例如侧摆角限制、下传要求）。记候选任务集合为 $\mathcal{O}$。一个计划 $P = (o_1, o_2, \ldots, o_m)$ 是一串按时间排序的被选观测，其中 $o_i \in \mathcal{O}$ 且每个任务至多出现一次。计划的效用为 $U(P) = \sum_{i=1}^{m} u(o_i)$。

2) 可行性约束: 计划 P 是可行的，当它满足：

- **可见窗口约束**：每个观测 o_i 必须安排在其窗口内：$t_i \in [w_{\text{start}}(o_i), w_{\text{end}}(o_i)]$，其中 t_i 是 o_i 在 P 中的开始时间。

- **机动间隔约束**：相邻观测之间必须留出足够的时间供卫星在目标之间侧摆。形式上，设 $\Delta(o_i, o_{i+1})$ 为 o_i 与 o_{i+1} 之间的最小侧摆时间，由二者的角度间隔和卫星的侧摆速率上限算出。我们要求 $t_{i+1} - (t_i + \mathrm{dur}(o_i)) \geq \Delta(o_i, o_{i+1})$，其中 $\mathrm{dur}(o_i)$ 是 o_i 的成像时长。
- **不重复约束**：每个观测在 P 中至多出现一次。

若所有约束都成立则记 $\mathrm{feasible}(P) = 1$，否则记 $\mathrm{feasible}(P) = 0$。

3) 已下发前缀约束下的修复问题： 设 $P = (o_1, \ldots, o_m)$ 为扰动前的参考计划。计划部分下发后，前 $k-1$ 个观测已承诺、不可修改。我们称 $F = (o_1, \ldots, o_{k-1})$ 为冻结前缀（或已下发前缀），$S = (o_k, \ldots, o_m)$ 为可编辑后缀。一个扰动 d 指定对任务集合或效用的一处改变：

- **取消**：某个已排任务 $o_c \in S$ 变得不可用，必须移除。
- **紧急插入**：一个新的高优先级任务 $o_u \notin P$ 到达，可行时应予以容纳。
- **奖励更新**：部分任务的效用发生改变，需要调整计划以捕获新的价值。

修复问题寻找一份新计划 P'，使得：

$$\max_{P'} \; U(P') \tag{1}$$

约束条件为：

$$P'[1 : k-1] = F \quad \text{（冻结前缀保持）} \tag{2}$$

$$\mathrm{feasible}(P') = 1 \quad \text{（对地观测约束）} \tag{3}$$

在效用相当的计划中，修复进一步偏好更小的任务集合改动（增删观测的数量）、更低的插入负担（新增任务的数量）和更小的时间偏移（保留任务的总计划移动）。因此，效用与干扰是问题定义的一部分，而非事后诊断。

4) 局部性与以扰动为中心的邻域： PALR 的一个关键设计选择是把编辑限制在一个以扰动为中心的邻域内。设 $\mathrm{pos}(d)$ 表示受扰动 d 影响最大的计划位置（例如被取消任务的下标，或紧急任务的优选插入点）。d 周围宽度为 w 的邻域定义为：

$$N_w(d) = \{o_i \in S : |\mathrm{index}(o_i) - \mathrm{pos}(d)| \leq w\} \tag{4}$$

PALR 把局部搜索限制在 $N_w(d)$ 内，从而给修复引发的干扰划定空间范围。$N_w(d)$ 之外的观测在修复后的计划中保持不动。

5) 插入预算控制： 为进一步限制修复强度，PALR 引入一个显式的插入预算 $B \in \mathbb{Z}_{\geq 0}$，用来给修复期间可新增的任务数量设上限：

$$|P'_{\mathrm{new}}| \leq B \tag{5}$$

其中 $P'_{\mathrm{new}} = P' \setminus P$ 是新插入观测的集合。参数 B 是一个可解释的控制旋钮：较小的 B 优先保证计划稳定，较大的 B 允许更激进的效用恢复。

C. 评测协议与复杂度

由于最接近的对地观测图神经搜索规划器的私有资产不可得，我们在一套统一的、论文内部认可的协议下评测所有方法，而不宣称严格复现 [3]。该协议保留了任务形式化、冻结前缀语义和所关心的修复指标，因此所有绝对数值只作为协议内部的比较来解读。我们用 $\mathrm{FR} \in [0, 1]$ 记冻结前缀比例：$\mathrm{FR} = 0$ 表示没有已下发前缀，$\mathrm{FR} = 0.6$ 表示修复开始前参考计划的 60% 已被承诺。所有方法都在同一实例生成器上执行，采用匹配的随机种子和相同的面向修复的指标集，因此时延被解读为共享评测路径下的相对修复代价，而非端到端任务系统时延。

精确修复问题在其自然判定形式下是 NP-难的。当 $\mathrm{FR} = 0$ 且没有局部编辑限制时，它退化为静态对地观测调度：在可见窗口和顺序相关机动约束下选择并排序一个效用最大化子集。这一基础问题在对地观测调度文献中已被公认为难解 [1], [3], [6]。已下发前缀和有界修复动作只会增添组合结构，而不会简化它。

D. 下发之后的失效模式与设计需求

已下发计划的对地观测调度并不是“静态规划外加一个扰动”。扰动会在一个部分承诺的结构中传播：取消会腾出局部空闲容量，这些容量是被利用还是被浪费取决于修复方法；紧急插入同时向响应性与承诺保持两个方向拉扯；奖励更新使拓扑结构保持不变，却打乱了价值排序。这揭示了纯以效用为中心的比较中的隐蔽失效模式——一个修复方法可能报告更高效用，却因依赖大量保留任务移动、大规模插入级联或违反已下发前缀而在操作上很弱。

上述分析指向面向可靠性的修复系统的五项设计需求。

- **G1：承诺保持**。冻结或已下发的前缀必须被显式建模；违反必须被报告，而不是被隐藏。

- **G2：低扰动适应**。方法应使任务集合改动、插入数量和被保留任务的时间移动保持较小。
- **G3：快速响应**。修复周期在计算上应显著低于更重的全局重规划或搜索。
- **G4：扰动覆盖**。修复方法应在单一修复视角下处理取消、紧急插入和奖励更新。
- **G5：可审计行为**。成功和失效模式应能通过显式的局部编辑和可度量的实际后果得到解释。

这些需求正是本文方法直接评估的组件：把插入预算 B 与冻结前缀有效性提升为一等的、可审计的对象。

IV. 方法：计划感知局部修复规则

A. 章节概述

本章节详细阐述我们提出的计划感知局部修复规则（PALR 规则）：给定一份参考计划、一个扰动描述符和冻结前缀边界，该规则输出一份修复后的计划以及效用、扰动和有效性诊断，如图2所示。

B. 整体框架

基于“下发计划不能被随意改动、扰动响应应保持局部”这一动机，以及“把承诺保持和插入规模都当作硬约束”这一核心原则，我们提出了以有界局部编辑为核心的 PALR 规则。首先，针对“已下发前缀不可修改”这一挑战，我们设计了冻结前缀保持机制；随后，为解决“修复引起的移动会向远处传播”这一挑战，我们设计了扰动中心邻域编辑机制；接着，引入显式插入预算 B 控制新接纳任务的规模；最后，三个机制通过一条修复流程串联起来，其中前缀保持与可行性作为硬约束、效用与扰动作为软目标，这样的选择使 PALR 成为一个修复方法而非通用重规划器。

C. 具体设计

模块 1（冻结前缀保持）： 该机制把已经进入操作协同链的计划部分锁定，使修复不触碰这些已承诺的决策，具体而言：

- 输入规范：参考计划 $P = (o_1, \ldots, o_m)$ 与第一个可编辑位置 k，其中前缀 $F = (o_1, \ldots, o_{k-1})$ 被视为冻结、后缀 $(o_k, \ldots, o_m)$ 可编辑；
- 公式描述：硬约束要求

$$P'[1 : k-1] = F, \tag{6}$$

  其中 P' 是修复后的计划，即前 $k-1$ 个观测在修复后必须与原计划逐位一致；
- 输出规范：得到一个只在 $i \geq k$ 处发生变化的候选计划，并满足冻结前缀逐位保持这一有效性标准。

该模块的输出（锁定的前缀和开放的后缀）作为输入传递给模块 2 和模块 3。

模块 2（扰动中心邻域编辑）： 为了把修复引起的移动限制在扰动附近，我们提出了邻域界定和局部候选池筛选两个组成部分，在扰动为局部的场景下达到“只重开必要后缀、其余保持不动”的效果。

- 组成 1（邻域界定）：采用以扰动边界为中心、宽度为 w 的解锁窗口，因为只有落在该窗口内的位置才被允许改动，形式上定义为

$$E(d, w) = \{o_i \in P \mid k \leq i \leq \min(m, b(d) + w - 1)\}, \tag{7}$$

  其中 d 是扰动描述符，$b(d)$ 是扰动 d 触及的第一个后缀位置，w 是邻域宽度；
- 组成 2（局部候选筛选）：使用 $E(d, w)$ 覆盖的时间跨度作为筛选条件，我们要求局部候选池 $U_{\text{loc}}(d, w) \subseteq U$ 只包含可见性窗口与该跨度或扰动释放的空闲相交的未排任务，从而使规则先在扰动的因果边界附近尝试吸收扰动，再考虑对后缀远处花费计算。

组成 1（邻域界定）是组成 2（局部候选筛选）的基础，二者为顺承关系。该模块的输入来自模块 1（锁定的前缀），其输出（解锁邻域和局部候选池）传递给模块 3。

模块 3（预算控制的修复算子）： 修复的算子空间围绕保留、替换和插入三种动作组织，主要由以下三个步骤依次组成：

- 步骤 1（保留）：对邻域内每个未被取消且与已构建部分相容的观测 o_i，将其按原位追加到 P'，该步骤在不移动被保留任务的前提下恢复局部可行性；
- 步骤 2（替换）：当邻域内某观测 o_i 可被局部候选池中效用更高的 o_j 取代且替换后仍可行时执行交换，形式上要求 $u(o_j) > u(o_i)$ 且 $\text{feasible}(P') = 1$，然后据此更新候选计划；
- 步骤 3（预算插入）：最后，在插入预算未耗尽时贪心地加入局部可行的新任务，具体来说，每次选取 $o_{\text{best}} = \arg\max_o \{u(o) : \text{feasible}(P' \cup \{o\}) = 1\}$ 并计入插入计数，直到达到预算上限。

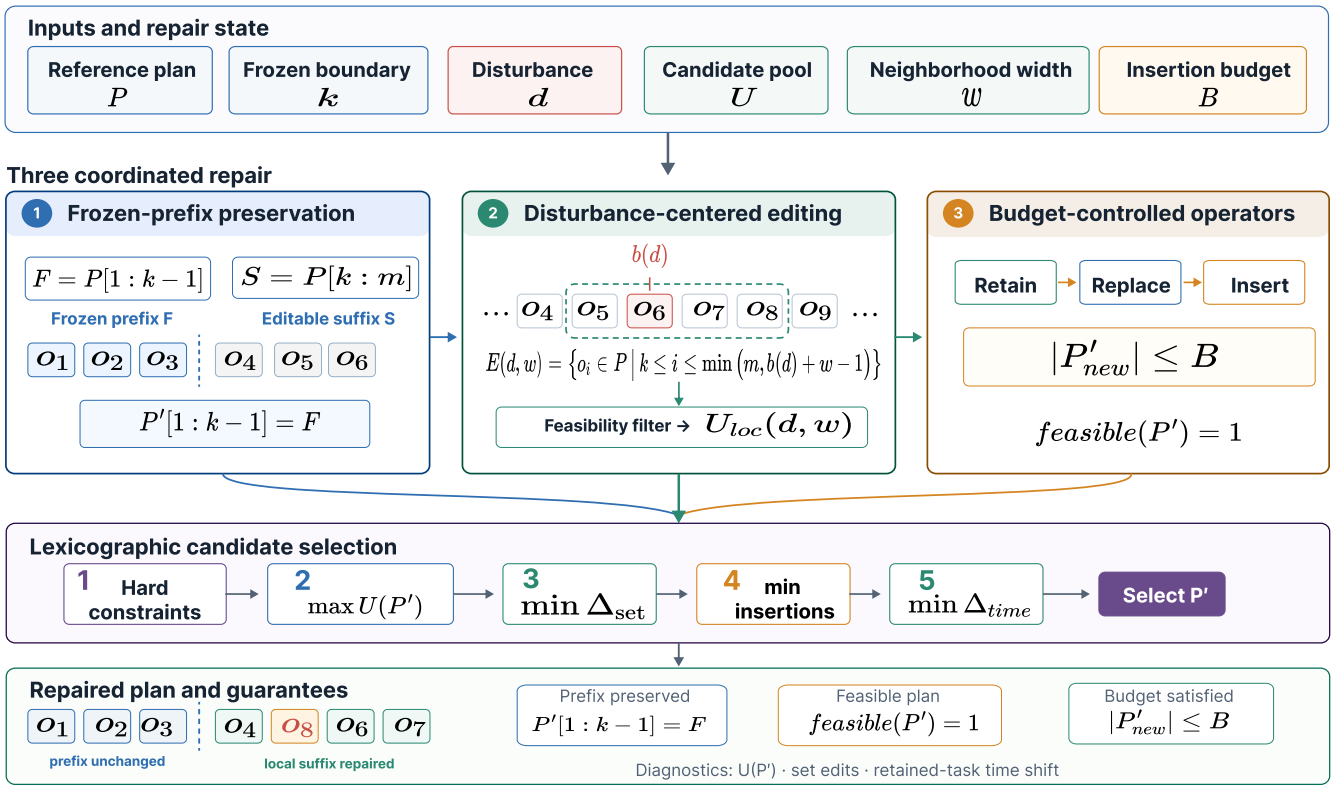


图 2. PALR 总体框架。方法以参考计划、冻结边界、扰动、候选池、邻域宽度和插入预算为输入，经冻结前缀保持、扰动中心邻域编辑与预算控制算子生成局部可行候选，并按照可行性、效用和干扰指标进行词典序裁决，得到保持冻结前缀的修复计划。

三个步骤具有严格的顺承关系，前一步骤是后一步骤的基础，需依次执行。该模块的输入来自模块 1 和模块 2，其输出作为系统最终的修复计划。插入步骤受硬约束

$$|\{a_i \in \pi : a_i = \text{Insert}(\cdot)\}| \le B \tag{8}$$

限制，其中 π 是施加在邻域内的算子序列，B 是插入预算。

D. 模块融合

为了应对“三类扰动需要在同一规则下统一处理”这一挑战，我们提出了以词典序偏好统一裁决候选计划的融合方式。由于效用恢复与扰动控制之间存在张力，为了区分硬约束和软目标，我们定义了如下裁决顺序，随后展开为一条修复流程：先拒绝任何改动冻结前缀或违反可行性的候选，再最大化恢复的效用，然后依次最小化任务集合改动、插入任务数量和被保留任务的时间移动。

算法3 把上述流程形式化。它以参考计划 P、冻结边界 k、扰动描述符 d、候选池 U、邻域宽度 w 和插入预算 B 为输入，返回一份保持 $F = P[1 : k-1]$ 并满足对地观测可行性的修复计划 P'。

段落总结：这种方法不仅能在取消场景下利用新释放的空闲恢复效用，而且能在奖励更新下不移动被保留任务地接纳新的高价值机会。由于前缀保持、局部邻域和插入预算这三个机制可以合并进同一条流程，达成了“默认使用低扰动局部修复、仅在必要时升级到更重搜索”这一核心目标。数学上，插入预算 B 是唯一经本文验证的控制变量：$B = 0$ 时方法退化为严格的稳定优先基线，增大 B 会扩大可接纳的插入集合，从而在效用恢复与调度稳定之间调节修复强度。

E. 性质与边界分析

命题 1 (前缀保持)**.** *设 $F = (o_1, \ldots, o_{k-1})$ 是输入计划 P 的冻结前缀。对于每一个合法输入，PALR 规则输出的修复计划 P' 满足 $P'[1 : k-1] = F$。*

a) 证明梗概。: 该规则只在可编辑后缀 $i \ge k$ 内构造候选。任何改动冻结前缀位置的候选都会在效用排序之前被拒绝，剩余候选还必须通过可行性检查。因

```
算法 1: PALR 规则
输入: P (参考计划), k (冻结边界),
      d (扰动), U (候选池),
      w (邻域宽度), B (插入预算)
输出: P' (修复后的计划)

1: F <- P[1:k-1]  // 冻结前缀
2: S <- P[k:m]    // 可编辑后缀
3: E <- BuildNeighborhood(S, d, w)
4: U_loc <- FilterCandidates(U, E)
5: P' <- F         // 以冻结前缀初始化
6:
7: // 步骤 1: 最小修复 (恢复可行性)
8: for each o_i in E do
9:    if o_i != 被取消任务 and Compatible(o_i, P') then
10:      P' <- P' union {o_i}  // 保留
11:   end if
12: end for
13:
14: // 步骤 2: 预算控制的插入
15: inserted <- 0
16: while inserted < B do
17:   o_best <- argmax_{o in U_loc\P'}
18:             {u(o) : Feasible(P' union {o})}
19:   if o_best 存在 then
20:     P' <- P' union {o_best}
21:     inserted <- inserted + 1
22:   else
23:     break  // 没有更多可行插入
24:   end if
25: end while
26:
27: return P'
```

图 3. PALR 修复规则。算法保持冻结前缀 F，在局部邻域 E 内恢复可行性，并贪心地插入至多 B 个新任务。

此每一个可接纳的输出都保持 F。命题 1 虽然基础，却是本文可靠性论证的核心：严格的紧急插入成功只在修复后的调度保持冻结前缀时才计为成功。

定理 1 (NP 困难性)**.** *动态对地观测卫星修复问题的判定版本是 NP 困难的。*

b) 证明梗概。: 当 $F = \emptyset$（没有冻结前缀）且预算无限时，修复问题退化为静态对地观测卫星调度，后者已被证明是 NP 困难的 [3], [6]。这一困难性结果为使用像 PALR 这样的有界启发式方法提供了依据，它以最优性换取速度和可预测性。

命题 2 (效用恢复的单调性)**.** *对固定输入，增大插入预算 B 绝不会降低修复计划的效用：当 $B_1 \le B_2$ 时 $U(P'_{B_1}) \le U(P'_{B_2})$。*

该证明源于算法3中的贪心插入策略。然而，单调性不推广到扰动指标：更高的预算会增加任务集合改动和插入负担，这在实验中得到观测。插入预算 B 因此定义了一条实用的修复前沿——在 $B = 0$ 时 PALR 退化为最小修复，更大的预算则扩展局部恢复，但可能违背低扰动的初衷。

这些结果也界定了当前的主张。在 FR $= 0$ 的紧急插入下，PALR 在数值上与最小修复完全相同，因此该规则尚不是一个更丰富的紧急放置机制，其被支持的角色更窄：一个可信的取消修复和奖励更新修复器，并带有一条有用的预算前沿。在重冻结前缀的紧急插入下，带学习先验的 PUCT 重规划器表明更强的搜索能在相同硬冻结约束下恢复更多效用，但代价是更大的任务集合扰动、更大的被保留任务移动以及约高两个数量级的延迟。所有保持前缀的方法都在 0.34 的严格紧急插入成功率处饱和（50 个实例中的 17 个），因此效用差距应被理解为在相同的严格成功上限内的比较。被支持的规则是：默认使用局部修复，仅当额外效用能够证明大幅更高的延迟和移动是值得的时才升级。

V. 实验

A. 实验设置

所有报告的主要结果都使用单一被接受的、与论文对齐的协议：50 个实例、每个实例 100 个候选观测、规划时域 $\tau = 5400$，并使用固定随机种子以保证可比性。我们评估三类扰动：取消、紧急插入和奖励更新。扰动在参考计划生成后施加，冻结前缀比例 FR 控制在修复开始前该计划已被承诺的比例。

为了更全面地评估本研究提出的 PALR 规则的性能，我们将其与两大类基线方法进行比较：全局重优化与稳定优先修复两类基线。全局重优化类以贪心全局重优化为代表，它是对地观测卫星中自然的全局规划基线 [2]–[6], [39]，愿意激进重开可编辑后缀；为加强与图引导树搜索规划的比较，我们在相同的冻结感知修复框架下报告两个推理期 PUCT 对比方法——一个启发式

PUCT 重规划器和一个带学习先验的变体，后者使用 40 次模拟、最大深度 12、top-k 候选控制 20、探索常数 1.5、浅层引导深度 2，以对地观测卫星图神经树搜索路线 [3] 和标准蒙特卡洛树搜索实践 [38] 为基础。稳定优先修复类以最小修复为代表，它遵循较新的稳定优先和有界扰动修复形式 [12]–[16]；当稳健性问题受益于额外的低扰动对比时，我们进一步纳入一个学习型局部修复变体和一个算子策略修复变体 [37]。学习先验行只改变搜索先验、不改变修复契约，因此被用作有信息量的对比方法，而非对完整图神经树搜索训练栈的复现。

实验通过以下四组指标评估保持承诺的修复质量：效用衡量修复计划的总观测价值，用于评估效用恢复能力；扰动组（任务集合改动、插入负担、被保留任务时间移动）衡量修复引入的计划改动，用于评估低干扰能力；延迟衡量共享评估路径上的相对修复成本，用于评估快速响应能力；严格有效性衡量在保持冻结前缀前提下的紧急插入成功率，用于评估承诺保持能力。这一分组是刻意的：本文的主要主张是，保持承诺的修复应通过联合面而非仅通过效用来评判。为保持双栏排版的可读性，我们对关键的接近比较报告均值 $\pm$ 95% 置信区间，使用自由度为 $n-1=49$ 的 t 分布计算；对效用、集合改动、插入负担和时间移动使用配对 t 检验，对延迟使用 Welch t 检验，并在多重比较时应用 Bonferroni 校正。

所有方法都在同一实例生成器上执行，采用匹配的随机种子和相同的面向修复的指标集。该协议与 [3] 的任务边界一致：相同的下发前缀修复问题、相同的可见性窗口和机动可行性结构、相同的面向修复的指标，但不复现该论文的私有资源或绝对奖励尺度。因此，所有报告的数值只在该协议内解释，延迟被读作相对修复代价，奖励更新的效用不跨扰动族比较。

B. 主要结果

a) 取消： 表I报告了本文中最清晰的正面结果。预算为 2 的 PALR 规则在效用上略微超过贪心全局重优化，同时保持零任务集合改动和零被保留任务时间移动。重要的限定是：PALR 规则应被理解为中间路线，而非在每个轴上都是最小扰动的赢家；当单独考虑插入负担时，最小修复仍是最保守的基线。在同一取消协议内，PALR 达到相同的效用区间，同时把插入任务负担从 0.539 降到 0.335、减少约 37.8%，消除被保留任务

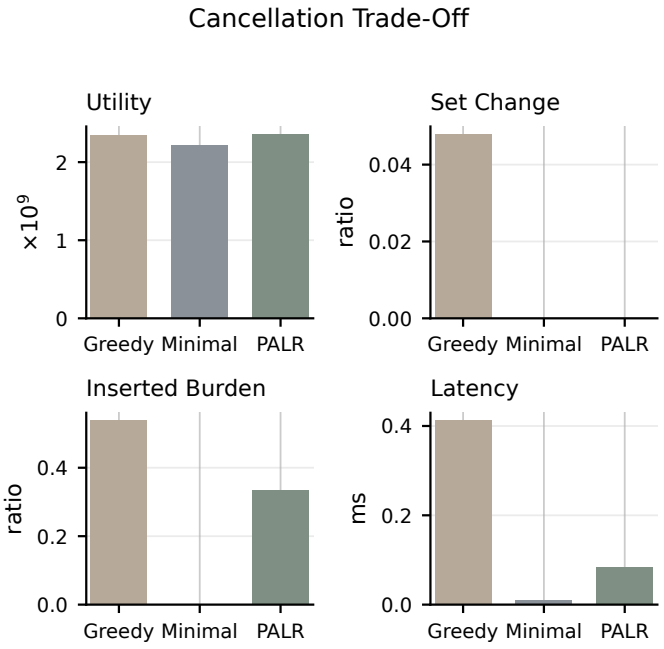


图 4. 取消场景在效用、集合改动、插入负担和延迟上的权衡。PALR 规则占据效用–扰动前沿的中间区域：最小修复是零插入端点，贪心全局重优化是激进重插入端点。

表 I
取消场景（50 个实例上的均值 $\pm$ 95% 置信区间）。效用单位为 $\times 10^9$。

方法	效用	集合改动	插入	移动	延迟
贪心全局重优化	2.348±0.259	0.048±0.028	0.539±0.422	24.6±12.1	0.413±0.041
最小修复	2.222±0.273	0.000	0.000	0.0	0.009±0.001
PALR 规则 (B=2)	2.362±0.273	0.000	0.335±0.108	0.0	0.084±0.005

移动，并把延迟从 0.413 毫秒降到 0.084 毫秒、降低约 79.7%。对操作者而言，这正是低扰动修复器优于激进后缀重建的实际有意义区间。

深入分析表明，取消结果应被读作一个权衡面而非单一得分的胜利。最小修复是零插入端点，贪心全局重优化是激进重插入端点，PALR 规则通过放弃部分保守性以夺回更多效用、同时在插入量和延迟上远低于贪心全局重优化，占据中间区间。因此 PALR 与贪心全局重优化之间的小效用差距不应被过度宣扬为大的绝对改进，其重要性是有条件的。

b) 紧急插入： 表II和III刻画了没有冻结前缀的紧急插入区间。核心事实是这一局限：PALR 规则在此设置下退化为最小修复，两行在效用和扰动上数值完全相同，微小的延迟差异可归因于实现开销。这一区间更支持下发前缀修复的框架，而非更丰富的紧急放置主张：三种方法都能放置紧急任务，但修复优先的方法族

表 II
无冻结前缀的紧急插入（均值 ± 95% 置信区间；FR = 0.0）。

方法	效用	集合改动	插入	移动
贪心全局重优化	2.417±0.276	0.142±0.061	0.168±0.041	34.4±21.6
最小修复	2.937±0.220	0.009±0.010	0.168±0.041	11.7±10.7
PALR 规则	2.937±0.220	0.009±0.010	0.168±0.041	11.7±10.7

表 III
紧急插入的延迟与严格成功率（在适用处为均值 ± 95% 置信区间；FR = 0.0）。

方法	延迟 (毫秒)	严格成功率
贪心全局重优化	0.406±0.044	1.00
最小修复	0.038±0.009	1.00
PALR 规则	0.039±0.013	1.00

以远小的调度移动做到这一点。当 FR = 0 且紧急任务已经能被一次最小局部编辑接纳时，当前 PALR 规则没有额外的排序信号来证明更激进的邻域扩展是合理的，因此本文把无冻结前缀的紧急插入作为边界情形、而非第二个头条胜利来呈现。

c) 奖励更新： 奖励更新暴露了第三种修复模式：当前 PALR 规则作为仅插入修复器，它把任务集合扰动和被保留任务移动保持为零，只通过额外插入来恢复效用。由于扰动本身改变了奖励尺度，表VIII和IX中的绝对效用值只应在各自表内比较。这一区别在实践上很重要，因为即使几何不变，奖励更新在滚动规划中也很常见；一个能够在不触碰被保留任务的情况下充实可编辑尾部的修复器，为操作者提供了一种在保持先前协同工作稳定的同时响应新价值估计的方式。代价是：当新的价值格局需要更深的结构性重排时，这样的修复器会表现不佳，这就是本文把奖励更新视为互补而非普适成功案例的原因。

C. 消融研究

为了量化评估插入预算这一使 PALR 规则可控的机制，我们在取消区间进行了预算扫描消融，结果汇总在表IV中。通过逐步增大预算 B，效用随预算增大而提升，但插入量和延迟也随之增长。预算 2 是最有依据的默认值，因为它在效用上已经匹配或略微超过贪心全局重优化，同时在插入量上远低于它、在延迟上更远低于它。

关键设计验证表明，引入正插入预算使操作模式从纯保持转为受控恢复，这表明插入预算与效用恢复之间

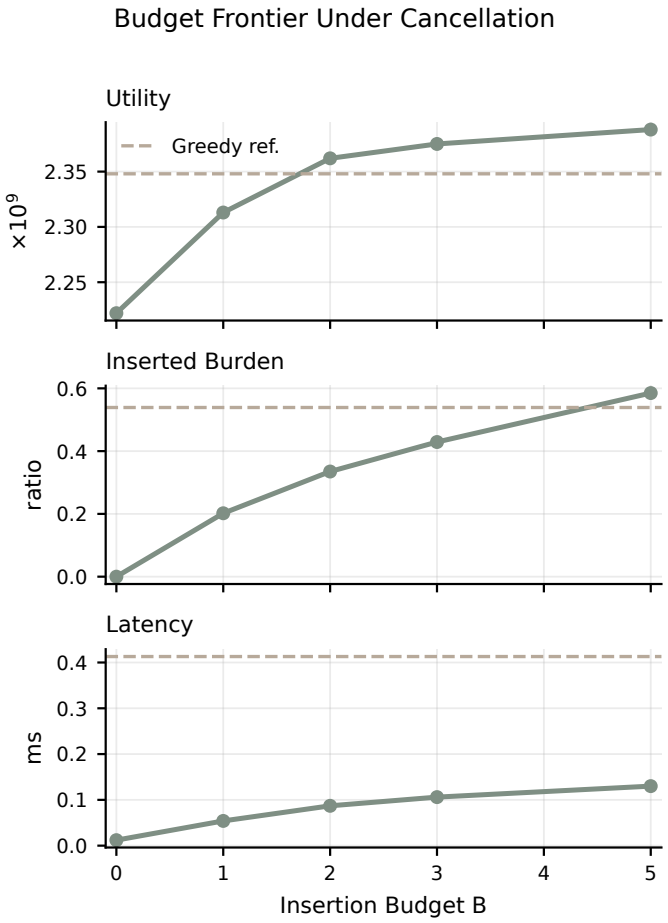


图 5. 取消预算前沿。最有依据的工作点是 $B = 2$：更大的预算仍能略微提升效用，但也会因增加插入负担而侵蚀低扰动优势。

表 IV
取消消融（均值 ± 95% 置信区间）。贪心全局重优化作为参考行纳入。

预算	效用 ($\times 10^9$)	插入任务比例	延迟 (毫秒)
贪心全局重优化 (参考)	2.348±0.259	0.539±0.422	0.413±0.041
$B = 0$	2.222±0.273	0.000	0.012±0.001
$B = 1$	2.313±0.271	0.202±0.056	0.054±0.004
$B = 2$	2.362±0.273	0.335±0.108	0.087±0.007
$B = 3$	2.375±0.274	0.429±0.145	0.106±0.010
$B = 5$	2.388±0.276	0.585±0.229	0.130±0.018

存在显著的单调正相关关系，从而验证了我们把 B 作为可解释控制变量的设计动机的有效性。从 $B = 0$ 到 $B = 2$ 把操作模式从纯保持改为受控恢复，而从 $B = 2$ 到 $B = 5$ 把方法推向越来越激进的后缀修改；$B = 2$ 之后效用曲线的平坦，加上插入任务负担的持续增长，正是本文把 $B = 2$ 视为最可信默认值而非孤立数值最优的原因。总体来说，本消融研究证明了插入预算在 PALR 规则中不可或缺的性质：它不是一个装饰性超参

表 V
重冻结约束下的取消稳健性（均值 ± 95% 置信区间）。效用单位为 $\times 10^9$。

设置	方法	效用	集合改动	插入	移动
FR = 0.6, 强度 = 0.5					
	贪心全局重优化	2.413±0.270	0.056±0.028	0.597±0.417	12.5±8.3
	最小修复	2.298±0.289	0.000	0.000	0.0
	PALR 规则 (B=2)	2.398±0.275	0.000	0.313±0.110	0.0
FR = 0.6, 强度 = 1.0					
	贪心全局重优化	2.373±0.258	0.053±0.029	0.564±0.419	20.0±9.3
	最小修复	2.256±0.277	0.000	0.000	0.021±0.042
	PALR 规则 (B=2)	2.364±0.268	0.000	0.342±0.106	0.021±0.042

数，而是一个花费插入容量以夺回效用、同时保持修复局部且可审计的明确决定。

D. 稳健性评估

稳健性结果澄清了何时应该以及不应该信任 PALR。我们聚焦于最清晰地对承诺保持施压的区间：重冻结前缀、严格有效性下的紧急插入，以及非拓扑的奖励变化。

1) 重冻结前缀下的取消： 表V表明，在冻结比例 0.6 下，PALR 规则仍接近贪心全局重优化的效用，同时保持零任务集合扰动和基本为零的被保留任务移动。这是更干净的重冻结成功案例：可编辑尾部很小，但有界修复仍能在不重开被保留工作的情况下恢复大部分可用价值。使这一区间重要的是，可编辑尾部在扰动发生前就已经很短，因此在不移动被保留工作的情况下恢复效用比在基础取消设置中更难；PALR 在两种强度下都保持在贪心全局重优化的效用带附近，支持了更窄的主张：当扰动可被尾部级重排吸收时，有界局部修复仍然可行。

2) 重冻结前缀下的紧急插入： 重冻结紧急区间是最强效用导向对比方法最重要的地方。表VI和VII表明，学习先验 PUCT 对比方法在硬冻结约束下达到最高效用，但它付出比局部修复族大得多的延迟和移动。严格紧急成功上限对每种保持前缀的方法都是 0.34，对应 50 个评估实例中的 17 个。这表明一旦施加 FR = 0.6，约 33 个实例在当前生成器下不可行，因此搜索优势应在同一可行子集内解读，而不是作为更多可行实例的证据。这正是本文想要揭示的操作升级故事：当严格成功上限被可行性固定时，更强的搜索改变的是成功修复的质量，而不是严格成功实例的数量。

同一张表也澄清了我们为什么不把学习先验 PUCT 行视为无条件的全局赢家：它的额外效用伴随着明显更大的插入任务负担，以及相对于低扰动修复约一个数量级的延迟惩罚。本文并不隐瞒更强搜索能在效用上取胜的事实，而是把这份额外效用的代价说清楚，并明确给出分母：在这个生成器中，所有方法都被限制在相同的 50 个中 17 个严格成功。

3) 奖励更新作为非拓扑扰动： 表VIII和IX报告了跨两个冻结比例和两个扰动强度的奖励更新网格。关键观察是：当前 PALR 规则表现为仅插入修复器，它保持原有被保留计划不变，并通过在可编辑尾部追加或激活新机会来获得效用；相比之下，贪心全局重优化通过更激进地重开后缀来获得效用，这会增加移动和任务集

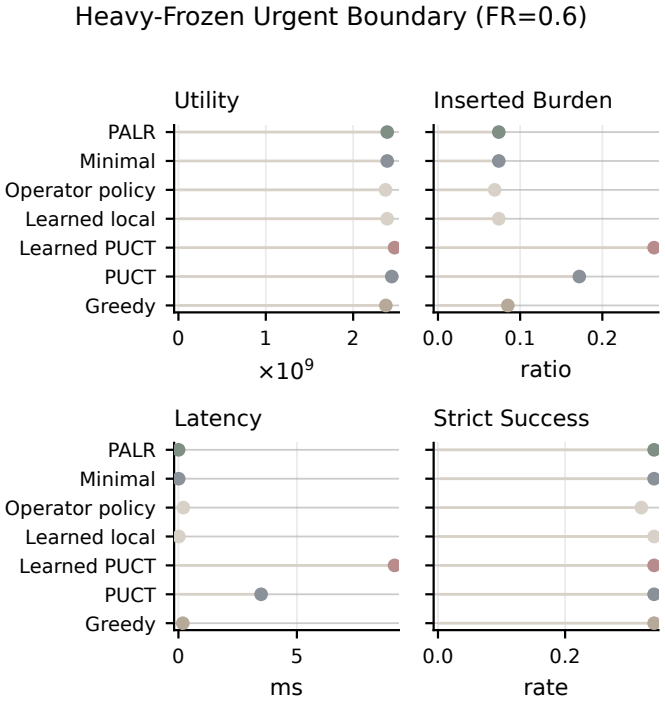


图 6. FR = 0.6 处的重冻结紧急边界。更强的搜索在相同的严格成功上限内提升紧急效用，但付出比局部修复大得多的延迟和更大的插入任务负担。

表 VI
重冻结紧急插入（均值 ± 95% 置信区间；FR = 0.6）。两个 PUCT 行共享相同的 40 次模拟预算，PALR 规则与最小修复在当前实现中共享相同的紧急修复决策。

方法	效用	集合改动	插入	移动
贪心全局重优化	2.374±0.220	0.041±0.027	0.085±0.049	2.4±1.6
PUCT 重优化	2.442±0.220	0.041±0.027	0.172±0.127	2.8±1.7
学习先验 PUCT	2.474±0.224	0.056±0.026	0.263±0.158	9.5±3.1
学习型局部修复	2.390±0.223	0.028±0.022	0.074±0.045	0.4±0.5
算子策略修复	2.370±0.223	0.034±0.023	0.069±0.045	0.6±0.6
最小修复	2.390±0.223	0.028±0.022	0.074±0.045	1.9±1.5
PALR 规则	2.390±0.223	0.028±0.022	0.074±0.045	1.9±1.5

表 VII

重冻结紧急插入：延迟与严格成功率（在适用处为均值 ± 95% 置信区间；FR = 0.6）。

方法	延迟 (毫秒)	严格成功率
贪心全局重优化	0.184±0.013	0.34
PUCT 重优化	3.489±0.440	0.34
学习先验 PUCT	9.122±1.813	0.34
学习型局部修复	0.021±0.009	0.34
算子策略修复	0.209±0.020	0.32
最小修复	0.011±0.003	0.34
PALR 规则	0.008±0.002	0.34

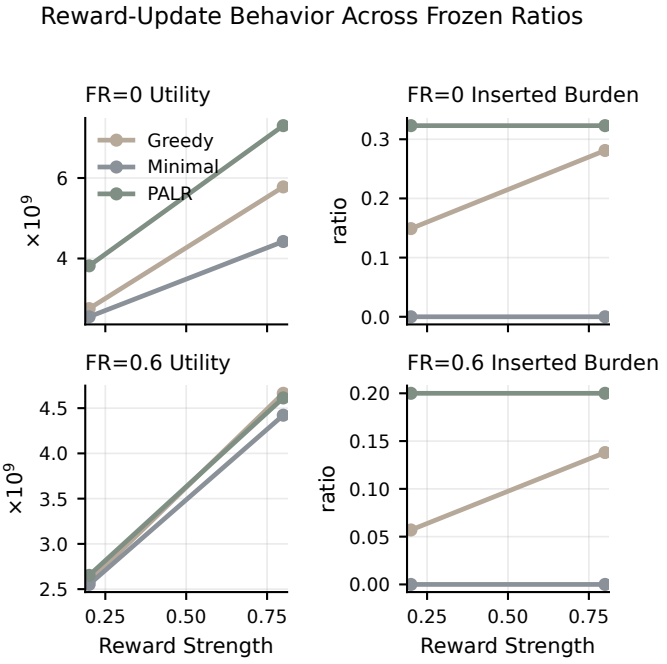


图 7. 跨冻结比例的奖励更新行为。PALR 规则表现为仅插入修复器：它保持被保留工作，但一旦可编辑尾部变小，其效用优势就急剧收窄。

合改动。

奖励更新表最好被读作两种不同的修复模式。在 FR = 0 时，PALR 规则可以花费少量插入来收获大的效用增益，而不移动被保留工作；在 FR = 0.6 时，同一策略被挤进一个薄得多的可编辑尾部，保持性仍然成立，但价值恢复的空间大部分消失。因此，奖励更新比其他扰动更清晰地把“稳定几何下的价值收获”与“深度重排”区分开来。

E. 兼容性研究

为了证明 PALR 规则与其他技术路线的正交性及兼容潜力，我们将其与外部的推理期 PUCT 搜索和学习先验结合到相同的冻结感知修复框架下。实验表明，

表 VIII

无冻结前缀的奖励更新（均值 ± 95% 置信区间；FR = 0.0）。效用单位为 $\times 10^9$，仅在此扰动族内可比。

强度	方法	效用	集合	增加	移动
0.2	贪心全局重优化	2.755±0.308	0.132±0.049	0.149±0.041	36.5±15.8
0.2	最小修复	2.552±0.298	0.000	0.000	0.0
0.2	PALR 规则	3.818±0.321	0.000	0.323±0.053	0.0
0.8	贪心全局重优化	5.779±0.784	0.239±0.052	0.281±0.071	61.8±17.5
0.8	最小修复	4.422±0.701	0.000	0.000	0.0
0.8	PALR 规则	7.301±0.767	0.000	0.323±0.053	0.0

表 IX

重冻结前缀下的奖励更新（均值 ± 95% 置信区间；FR = 0.6）。效用单位为 $\times 10^9$，仅在此扰动族内可比。

强度	方法	效用	集合	增加	移动
0.2	贪心全局重优化	2.583±0.298	0.041±0.032	0.057±0.031	2.2±1.6
0.2	最小修复	2.552±0.298	0.000	0.000	0.0
0.2	PALR 规则	2.652±0.297	0.000	0.200±0.064	0.0
0.8	贪心全局重优化	4.664±0.754	0.076±0.037	0.138±0.064	10.2±4.5
0.8	最小修复	4.422±0.701	0.000	0.000	0.0
0.8	PALR 规则	4.613±0.712	0.000	0.200±0.064	0.0

在重冻结紧急区间，结合后的学习先验 PUCT 方案在保持相同 0.34 严格成功上限的前提下把紧急效用进一步提升至 2.474（相对贪心全局重优化的 2.374 提升约 4.2%）。这一结果表明 PALR 的修复契约具备良好的可组合性，能够有效吸纳外部搜索与学习增强信息，突出了本文方法在“默认快速局部修复、必要时升级到更强搜索”这一分层调度场景方面的强大适应性与有效性。延迟证据同样支持这一分层视角：PALR 在整个被接受的协议中保持亚毫秒级，贪心全局重优化慢几倍，学习先验 PUCT 重规划器在最难的重冻结紧急设置下约慢两个数量级（9.122 毫秒对 0.008 毫秒），因此有界局部修复足够便宜，可以在固定的对地观测卫星契约下充当默认快速路径。

VI. 结论

我们把动态对地观测调度刻画为对部分已发布计划的修复，并把 PALR 作为一种有界局部响应加以评估。结果在取消之后最清晰地支持 PALR：它匹配贪心全局重优化的效用带，同时引入的扰动远小于后者。奖励变化展示了第二种情形，其中不变的几何让 PALR 能通过小规模尾部插入获得价值，而不重开保留工作。它的界限也是明确的：没有冻结前缀时紧急插入退化为最小修复；当 FR = 0.6 时，更强的搜索只在同一 50

中 17 的严格成功上限内提高价值，且延迟与移动更大。因此，PALR 不是更重搜索的通用替代品，而是一种可信的快速首次响应，其升级条件可通过实验识别。

参考文献

[1] B. Ferrari, J.-F. Cordeau, M. Delorme, M. Iori, and R. Orosei, "Satellite scheduling problems: A survey of applications in earth and outer space observation," *Computers & Operations Research*, vol. 173, p. 106875, 2025. [Online]. Available: https://doi.org/10.1016/j.cor.2024.106875

[2] S. Krigman, T. Grinshpoun, and L. Dery, "Scheduling of earth observing satellites using distributed constraint optimization," *Journal of Scheduling*, vol. 27, pp. 507–524, 2024. [Online]. Available: https://doi.org/10.1007/s10951-024-00816-x

[3] A. Jacquet, G. Infantes, E. Benazera, V. Baudoui, J. Guerra, and S. Roussel, "Earth observation satellite scheduling with graph neural networks and monte carlo tree search," 2024. [Online]. Available: https://arxiv.org/abs/2408.15041

[4] J. Qi, M. Hu, L. Xing, and Z. Su, "Deep reinforcement learning-assisted large neighborhood search for online scheduling large-scale emergency tasks to earth-observing satellites," *Expert Systems with Applications*, vol. 291, p. 128502, 2025. [Online]. Available: https://doi.org/10.1016/j.eswa.2025.128502

[5] X. Feng, Y. Li, and M. Xu, "Multi-satellite cooperative scheduling method for large-scale tasks based on hybrid graph neural network and metaheuristic algorithm," *Advanced Engineering Informatics*, vol. 60, p. 102362, 2024. [Online]. Available: https://doi.org/10.1016/j.aei.2024.102362

[6] M. Caleiras, S. Moniz, and P. Nascimento, "A constraint programming model for the super-agile earth observation satellite imaging scheduling problem," in *Proceedings of the 15th International Conference on Operations Research and Enterprise Systems*, 2026, pp. 110–121. [Online]. Available: https://doi.org/10.5220/0014407000004055

[7] P. Li, H. Wang, Y. Zhang, and R. Pan, "Mission planning for distributed multiple agile earth observing satellites by attention-based deep reinforcement learning method," *Advances in Space Research*, vol. 74, no. 5, pp. 2388–2404, 2024. [Online]. Available: https://doi.org/10.1016/j.asr.2024.06.003

[8] P. Li, P. Cui, and H. Wang, "Mission sequence model and deep reinforcement learning-based replanning method for multi-satellite observation," *Sensors*, vol. 25, no. 6, p. 1707, 2025. [Online]. Available: https://doi.org/10.3390/s25061707

[9] H. Li, Y. Li, Q. Q. Meng, X. Li, L. Shao, and S. Zhao, "An onboard periodic rescheduling algorithm for satellite observation scheduling problem with common dynamic tasks," *Advances in Space Research*, vol. 73, no. 11, pp. 5242–5253, 2024. [Online]. Available: https://doi.org/10.1016/j.asr.2024.02.038

[10] Y. Long, C. Shan, W. Shang, J. Li, and Y. Wang, "Deep reinforcement learning-based approach with varying-scale generalization for the earth observation satellite scheduling problem considering resource consumptions and supplements," *IEEE Transactions on Aerospace and Electronic Systems*, vol. 60, no. 3, pp. 2572–2585, 2024. [Online]. Available: https://doi.org/10.1109/TAES.2024.3379169

[11] J. Chen, F. Wang, Y. Chen, L. He, Y. Du, J. Wu, and Y. Chen, "A generalized bilevel optimization model for large-scale task scheduling in multiple agile earth observation satellites," *Knowledge-Based Systems*, vol. 309, p. 112809, 2025. [Online]. Available: https://doi.org/10.1016/j.knosys.2024.112809

[12] S. Holguin Jimenez, W. Trabelsi, and C. Sauvey, "Multi-objective production rescheduling: A systematic literature review," *Mathematics*, vol. 12, no. 20, p. 3176, 2024. [Online]. Available: https://doi.org/10.3390/math12203176

[13] C. Zhang, M. Juraschek, and C. Herrmann, "Deep reinforcement learning-based dynamic scheduling for resilient and sustainable manufacturing: A systematic review," *Journal of Manufacturing Systems*, vol. 77, pp. 962–989, 2024. [Online]. Available: https://doi.org/10.1016/j.jmsy.2024.10.026

[14] N. Ouahabi, A. Chebak, O. Kamach, O. Laayati, and M. Zegrari, "Leveraging digital twin into dynamic production scheduling: A review," *Robotics and Computer-Integrated Manufacturing*, vol. 89, p. 102778, 2024. [Online]. Available: https://doi.org/10.1016/j.rcim.2024.102778

[15] S. Lendl, U. Pferschy, and E. Rener, "Rescheduling with new orders under bounded disruption," *INFORMS Journal on Computing*, vol. 36, no. 6, pp. 1654–1675, 2024. [Online]. Available: https://doi.org/10.1287/ijoc.2023.0038

[16] R. Chen, T. C. E. Cheng, C. T. Ng, J.-Q. Wang, H. Wei, and J. Yuan, "Rescheduling to trade off between global disruption of original jobs with flexibility and scheduling cost of new jobs," *Omega*, vol. 128, p. 103114, 2024. [Online]. Available: https://doi.org/10.1016/j.omega.2024.103114

[17] Y. Bengio, A. Lodi, and A. Prouvost, "Machine learning for combinatorial optimization: A methodological tour d'horizon," *European Journal of Operational Research*, vol. 290, no. 2, pp. 405–421, 2021. [Online]. Available: https://doi.org/10.1016/j.ejor.2020.07.063

[18] N. Sonnerat, P. Wang, I. Ktena, S. Bartunov, and V. Nair, "Learning a large neighborhood search algorithm for mixed integer programs," 2021. [Online]. Available: https://arxiv.org/abs/2107.10201

[19] Y. Wu, W. Song, Z. Cao, and J. Zhang, "Learning large neighborhood search policy for integer programming," 2021. [Online]. Available: https://arxiv.org/abs/2111.03466

[20] A. Hottung and K. Tierney, "Neural large neighborhood search for routing problems," *Artificial Intelligence*, vol. 313, p. 103786, 2022. [Online]. Available: https://doi.org/10.1016/j.artint.2022.103786

[21] R. Reijnen, Y. Zhang, H. C. Lau, and Z. Bukhsh, "Online control of adaptive large neighborhood search using deep reinforcement learning," 2022. [Online]. Available: https://arxiv.org/abs/2211.00759

[22] G. Hendel, "Adaptive large neighborhood search for mixed integer programming," *Mathematical Programming Computation*, vol. 14, no. 2, pp. 185–221, 2022. [Online]. Available: https://doi.org/10.1007/s12532-021-00209-7

[23] J. Zhou, Y. Wu, Z. Cao, W. Song, J. Zhang, and Z. Chen, "Learning large neighborhood search for vehicle routing in airport ground handling," 2023. [Online]. Available: https://arxiv.org/abs/2302.13797

[24] T. M. Mazzoli, L. Kletzander, P. Van Hentenryck, and N. Musliu, "Investigating large neighbourhood search for bus driver scheduling," in *Proceedings of the 34th International Conference on Automated Planning and Scheduling (ICAPS)*, 2024, pp. 360–368. [Online]. Available: https://doi.org/10.1609/icaps.v34i1.31495

[25] J. Cai, T. Huang, and B. Dilkina, "Learning backdoors for mixed integer linear programs with contrastive learning," in *ECAI 2024*, 2024. [Online]. Available: https://doi.org/10.3233/faia240768

[26] W. Chen, S. Koenig, and B. Dilkina, "Marl-lns: Cooperative multi-agent reinforcement learning via large neighborhoods search," 2024. [Online]. Available: https://arxiv.org/abs/2404.03101

[27] C. Gao, H. Shang, K. Xue, D. Li, and C. Qian, "Towards generalizable neural solvers for vehicle routing problems via ensemble with transferrable local policy," in *Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI)*, 2024, pp. 6914–6922. [Online]. Available: https://doi.org/10.24963/ijcai.2024/764

[28] A. I. Garmendia, Q. Cappart, J. Ceberio, and A. Mendiburu, "MARCO: A memory-augmented reinforcement framework for combinatorial optimization," in *Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI)*, 2024, pp. 6931–6939. [Online]. Available: https://doi.org/10.24963/ijcai.2024/766

[29] Z. Lin, Y. Wu, B. Zhou, Z. Cao, W. Song, Y. Zhang, and S. Jayavelu, "Cross-problem learning for solving vehicle routing problems," in *Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI)*, 2024, pp. 6958–6966. [Online]. Available: https://doi.org/10.24963/ijcai.2024/769

[30] T. Wu, H. Cui, T. Guan, Y. Wang, and Y. Jin, "ReinforceNS: Reinforcement learning-based multi-start neighborhood search for solving the traveling thief problem," in *Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI)*, 2024, pp. 7038–7046. [Online]. Available: https://doi.org/10.24963/ijcai.2024/778

[31] J. Zhang, C. Luo, Z. Su, Q. Zhang, Z. Lu, J. Ding, and Y. Jin, "NS4S: Neighborhood search for scheduling problems via large language models," in *Proceedings of the Thirty-Fourth International Joint Conference on Artificial Intelligence (IJCAI)*, 2025, pp. 8687–8695. [Online]. Available: https://doi.org/10.24963/ijcai.2025/966

[32] H. Ye, J. Wang, H. Liang, Z. Cao, Y. Li, and F. Li, "GLOP: Learning global partition and local construction for solving large-scale routing problems in real-time," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, no. 18, 2024, pp. 20 284–20 292. [Online]. Available: https://doi.org/10.1609/aaai.v38i18.30009

[33] Z. Sun and Y. Yang, "DIFUSCO: Graph-based diffusion solvers for combinatorial optimization," in *Advances in Neural Information Processing Systems 36*, 2023. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2023/hash/0ba520d93c3df592c83a611961314c98-Abstract-Conference.html

[34] S. Attieh, N. Dang, C. Jefferson, I. Miguel, and P. Nightingale, "Athanor: Local search over abstract constraint specifications," *Artificial Intelligence*, vol. 340, p. 104277, 2025. [Online]. Available: https://doi.org/10.1016/j.artint.2024.104277

[35] Z. Liu, W. Xiong, C. Han, and X. Yu, "Deep reinforcement learning with local attention for single agile optical satellite scheduling problem," *Sensors*, vol. 24, no. 19, p. 6396, 2024. [Online]. Available: https://doi.org/10.3390/s24196396

[36] Q. Cappart, D. Chételat, E. B. Khalil, A. Lodi, C. Morris, and P. Velickovic, "Combinatorial optimization and reasoning with graph neural networks," *Journal of Machine Learning Research*, vol. 24, no. 130, pp. 1–61, 2023. [Online]. Available: https://jmlr.org/papers/v24/22-0459.html

[37] S. Brody, U. Alon, and E. Yahav, "How attentive are graph attention networks?" 2021. [Online]. Available: https://arxiv.org/abs/2105.14491

[38] T. Cazenave, "Batch monte carlo tree search," 2021. [Online]. Available: https://arxiv.org/abs/2104.04278

[39] X. Wang, F. Zhao, Z. Shi, and Z. Jin, "Deep reinforcement learning-based periodic earth observation scheduling for agile satellite constellation," *Journal of Aerospace Information Systems*, vol. 20, no. 8, pp. 508–519, 2023. [Online]. Available: https://doi.org/10.2514/1.I011209